

卒論 ノート

氏名：久野証

所属：東大工学部計数工学科数理情報工学コース

学籍番号: 03-210599

2023 年 9 月 28 日

目次

1	Papers	2
1.1	Emergence of a resonance in machine learning	2
2	Lectures	8
2.1	Josef Teichmann: Reservoir Computing for SDEs	8
3	TODOs	10

概要

2023 年 A セメスターの卒論執筆に際して、勉強したことや考えたことのメモをここにまとめた。

1 Papers

1.1 Emergence of a resonance in machine learning

Zheng-Meng Zhai , 1 Ling-Wei Kong , 1 and Ying-Cheng Lai 1,2,* 1School of Electrical, Computer and Energy Engineering, Arizona State University, Tempe, Arizona 85287, USA 2Department of Physics, Arizona State University, Tempe, Arizona 85287, USA.

(Received 9 June 2022; revised 1 March 2023; accepted 26 July 2023; published 24 August 2023)

キーワード：Resonance in nonlinear dynamical systems,

1.1.1 要旨

1. 入力信号にノイズを挿れた場合の Reservoir Computing を考える。
 - (a) 47 によれば、training phase と testing phase のノイズ振幅が同じ時 RC は最も良いパフォーマンスを発揮する。
 - (b) hyperparameters が最適化されていない時でも、ノイズを挿れることで予測の精度をあげることができる。
 - (c) もっとも良い精度を達成するには、hyperparameters が最適化されていなければならない。
 - i. Hyperparameters に対する Bayesian optimization で最適化可能。
 - ii. 確率共鳴があると決定づけるために、ノイズの振幅を hyperparameter に数える。
2. Macky-Glass (MG) system と Kuramoto-Sivashinsky (KS) system に対して、シミュレーションを行う。
3. 物理側から、確率共鳴が生まれる原理を考える。

1.1.2 手法

1. MG/KS system に対して、Bayesian Optimization で最適な hyperparameters (σ を含む) を決定する。
2. σ を最適値から両側に動かして、 σ ごとに他の hyperparameters の最適値を決定する。
3. σ について、予測誤差を観察することによって、確率共鳴があることを確かめる。

1.1.3 状況設定

Appendix A 参照。

1. hyperparameters:

- (a) ρ : the spectral radius of the reservoir network.
- (b) γ : the scaling factor of the input weights.
- (c) α : the leakage parameter
- (d) β : the regularization coefficient
- (e) p : the link connection probability of the random network in the hidden layer.
- (f) σ : the noise amplitude, taking value between $[10^{-8}, 10^{0.5}]$.

2. hyperparameters の最適化

- (a) MATLAB: SURROGATEOPT を用いる。^{*1}
- (b) σ ごとに hyperparameters の最適化を行うので、 σ に対する他の hyperparameters の組みは異なる。

3. シミュレーションを行う。

(a) MG system:

$$\dot{s}(t) = \frac{as(t - \tau)}{(1 + [s(t - \tau)]^c) - bs(t)},$$

τ is the time delay, a, b , and c are parameters. ^{*2}

- i. $a = 0.2, b = 0.1$, and $c = 10$ を固定。
- ii. $\tau = 17, 30$ の 2 つの場合を比べる。
- iii. 時系列データには事前に z-score normalization: $z(t) = [s(t) - \bar{s}]/\sigma_s$ を施す。

(b) KS system:

$$\frac{\partial u}{\partial t} + \mu \frac{\partial^4 u}{\partial x^4} + \phi \left(\frac{\partial^2 u}{\partial x^2} + u \frac{\partial u}{\partial x} \right) = 0$$

- i. $u(x, t)$ is a scalar field defined in the spatial domain $0 \leq x \leq L$.
- ii. $\mu = 1$ and $\phi = 1$, and use the periodic boundary condition.

^{*1} "The Bayesian optimization method can be implemented using PYTHON or other languages. Different packages for Bayesian optimization are now available, such as BAYESIAN-OPTIMIZATION and BOTORCH in PYTHON."としている。

^{*2} The state of the system at time t is determined by the entire prior state history within the time delay, making the phase space of the system infinitely dimensional.

iii. $L = 60$, where the system has seven positive Lyapunov exponents:

$$\lambda_+ \approx 0.089, 0.067, 0.055, 0.041, 0.030, 0.005, \text{ and } 0.003.$$

4. それぞれに対する ESN の変数設定は表 1 にある。

	MG	KS
Warmup	$10000\Delta t$	300 Lyapunov times
Training phase	$150000\Delta t$	1000 Lyapunov times
Testing phase for Bayesian optimization	$900\Delta t$	—
Short-term prediction	$900\Delta t$	6 Lyapunov times
Long-term prediction	$20000\Delta t$	200 Lyapunov times

表 1 論文中の ESN に関する変数設定

1.1.4 面白いと思ったところ

1. ノイズを入れることによって、本来初期値鋭敏性を持つカオスシステムに対して、短期的にも長期的にも予測の精度を上げられる。
2. Bollt[40] の結果を用いることで、本来 high-dimensional neural network の複雑な dynamics に対して簡略化された物理モデルを得ることができ、それに対する解析によって RC の hidden layer の中身を説明できる。
→ 同じ手法で、この物理モデルを用いることで、他の現象が neural network の dynamics においても現れることを発見・説明できるかもしれない？

1.1.5 疑問点

1. Fig.4 と Fig.5 について、MG system における τ の値が 30 から 17 に変えると、 σ にどのような影響があるか。なぜその影響が生まれるか。
2. なぜ、Fig.2 の（逆）ピークを与える σ 帯と Fig.6(c) の（逆）ピークを与える σ 帯が重なるのか。
3. III で、Machine learning における resonance が生まれる Physical reason を挙げているが、これは対象を正しく説明できているか。extraordinarily complicated な hidden layer の中身を解析することなく、physical reason を与えることが、なにを説明しているのか/なにを説明していないのか。
→ Bollt[40] の結果？

4. そもそも、short/long-term prediction の期間は何を表しているのか。

→ ある時刻 t の系の状態は時刻 $t - \tau$ から t までの情報で決定される。short/long-term に依らず定まった時間の warmup と training phase を設ける。(ここからは調べる必要あり) これによって、ESN は学習を済ませた状態になる。short/long-term の testing phase の長さの分だけ学習済みの ESN に予測をさせ、実際のデータとの誤差を計測する。

5. T_{opt} は ESN の学習のどの段階に設けられるのか。Training phase の後？

6. σ : noise amplitude 以外のパラメータの取りうる値の範囲は？

7. Bayesian optimization では何について最適化を行なっているのか？

→ KS システムの short-term prediction は RMSE, horizon prediction, stability を観察しているが、全て RMSE を基にしている。よって、最適化は RMSE を目的関数にとっているのではないか (reservoirpy のチュートリアルでは R^2 という距離も用いられている)。

8. RMSE, horizon prediction, stability でピークを与える σ が同じなのは、これらの手法の intrinsic な性質として導かれることか。それぞれの場合を切り離して計測することでどのような新しいことが言えるか。

1.1.6 論文を受けての今後の研究方向

1. short/long-term prediction での最適なパラメータは同じか、否か。

(a) 実験手法: short/long-term prediction それぞれに対して Bayesian optimization でパラメータの最適化を行い、一致するかどうか確かめる。

(b) 本文中では記載がないように思えるが、前提としている先行研究で明らかにされているかもしれない。

2. (些末な点?) 論文中では、予測誤差をいくつかの方法で表している (KS に対する short-term prediction だと RMSE, horizon prediction, stability 等)。Bayesian optimization の目的関数はどのように決まるか。目的関数の取り方によって、最適な hyperparameters はどのように変化するか。

3. (機械学習の知識が足りていない) 論文中では、MG, KS に対して、表 2 のようなパラメータで定数として hyperparameters の最適化を行なっている。hyperparameters ごとのこれらのパラメータの最適値は (大きく) 変化しないのか。

4. ノイズの入れ方: RC の hidden layer の入力信号に対するガウシアンノイズ以外に、どのようなノイズの入れ方と結果が考えられるか。

5. Bollt[40] の手法を理解し、力学系の理論で他に neural network の力学系に応用できる結果がないか探す。

	MG	KS
Warmup	$10000\Delta t$	300 Lyapunov times
Training phase	$150000\Delta t$	1000 Lyapunov times
Testing phase for Bayesian optimization	$900\Delta t$	—
Short-term prediction	$900\Delta t$	6 Lyapunov times
Long-term prediction	$20000\Delta t$	200 Lyapunov times

表 2 論文中の ESN に関する変数設定 (再掲)

1.1.7 関連する文献

1. Boltt[40]: Dynamics in nerual network の簡易物理モデルを与える。
2. [51]:
3. [57, 58]: Langevin 方程式に関する確率共鳴の理論。

1.1.8 用語まとめ

1.1.9 Abstract

stochastic/coherence resonance, nonlinear dynamical system, regularizer/regularization, reservoir computing, state variables/attractor, hyperparameters.

1.1.10 I. Introduction

model-free/data-driven, oscillation/Lyapunov times, trajectory, basin boundary, robustness, Bayesian optimization.

1.1.11 II. Result

SURROGATEOPT function (MATLAB), surrogate approximation function, objective function, global minimum, sampling/updating, radial basis function, Mackey-Glass (MG) system, spatiotemporal chaotic Kuramoto-Sivashinsky (KS) system.

1.1.12 A. Emergence of a resonance from short-term prediction

transient behavior, z-score normalization, periodic boundary condition, Prediction horizon/stability.

1.1.13 B. Emergence of a resonance from long-term prediction

collapse, wider/narrower resonance.

1.1.14 III. HEURISTIC REASON FOR THE OCCURRENCE OF A RESONANCE

time-scale match, the mean first-passage time, nonlinear activation, linear reservoir computing, noise-enhanced temporal regularity, vector autoregressive process (VAR).

1.1.15 IV. DISCUSSION

magnitude.

1.1.16 Appendix A

recurrent neural network(RNN), input/hidden/output layer, linear regression, adjacency matrix, state vector, dynamical state/evolution, neuron, leakage parameter α , link probability p , spectral radius.

2 Lectures

1. Reservoir Computing

- (a) [Reservoir Computing for SDEs\(Josef Teichmann:\)](#)
- (b) [Reservoir Computing & Dynamical Systems - Second Sumposium on Machine Learning and Dynamical Systems\(Josef Teichmann\)](#)
- (c) [Introduction to Next Generation Reservoir Computing\(Daniel Gauthier\)](#)

2. Machine Learning in general

- (a) [Machine Learning in Finance\(Josef Teichmann\)](#)

2.1 Josef Teichmann: Reservoir Computing for SDEs

[Access from here.](#)

1. We consider differential equations of the form

$$dY_t = \sum_i V_i(Y_t) du_t^i, Y_0 = y \in E$$

to construction evolutions in state space E (could be a manifold of finite or infinite dimension) depending on local characteristics, initial value $y \in E$ and the control u .

2. Theorem (Universality) Let Evol be a smooth evolution operator on a convenient vector space E which satisfies (again the time derivative is taken with respect to the forward variable t) a controlled ordinary differential equation

$$d\text{Evol}_{s,t}(x) = \sum_{i=1}^d V_i(\text{Evol}_{s,t}(x)) du^i(t).$$

Then for any smooth (test) function $f : E \rightarrow \mathbb{R}$ and for every $M \geq 0$ there is a time-homogenous linear $W = W(V_1, \dots, V_d, f, M, x)$ from \mathbb{A}_d^M to the real numbers \mathbb{R} such that

$$f(\text{Evol}_{s,t}(x)) = W(\pi_M(\text{Sig}_{s,t}(1))) + \mathcal{O}((t-s)^{M+1})$$

for $s \leq t$

3. Signature as universal dynamical system

- (a) This explains that any solution can be represented - up to a linear readout - by a universal reservoir, namely signature. Similar constructions can be done in regularity structures, too (branched rough paths, etc).
- (b) This is used in many instances of provable machine learning by, e.g., groups in Oxford (Harald Oberhauser, Terry Lyons, etc), and also ...
- (c) ... at JP Morgan, in particular great recent work on 'Nonparametric pricing and hedging of exotic derivatives' by Terry Lyons, Sina Nejad and Imanol Perez Arribas.
- (d) in contrast to reservoir computing: signature is high dimensional (i.e. infinite dimensional) and a precisely defined, non-random object.
- (e) Can we approximate signature by a lower dimensional random object with similar properties?

3 TODOs

1. [reservoirpy](#) 関連
 - (a) [Understand and optimize ESN hyperparameters](#) などの Tutorial ページを読む.
2. Reservoir Computing について学ぶ.
 - (a) レクチャーノートなどを通じて、知識を準備する。
3. ~~Github~~ 環境を整備する。9/28, Week2: branch の作り方がよくわからないが、とりあえず push は出来た。