

Reservoir Computer による外力付きカオス時系列モデルの予測と 生体リズム研究への応用

発表者：久野証

東京大学工学部計数工学科数理情報工学コース 4 年

December 7, 2023

目次

- 1 背景
- 2 これまでの結果
- 3 理論的な展開
- 4 Appendix
 - その他の主な結果
 - ReservoirPy (v0.3.10)
 - Hyperparameters の最適化
 - 先行研究
- 5 参考文献

LD Cycle による生体リズムの研究

概日リズムの研究：LD Cycle

- 常態的な時差ぼけや交代制勤務は、生活習慣病のリスクを高める。
- LD Cycle は生体リズムのモデルに用いられ、光と暗闇の情報が外力として系に加わる。
- 外力や各パラメータの設定により周期的・カオス的な振る舞いを持つ。
- 一般にカオスの予測は難しい。
 - ▶ 初期値鋭敏性。




Figure: Day 1 に 8 時間の Jet Lag を受けた時のマウスの Per2 の推移
Image: Fig.2 from [1].

Reservoir Computer を用いたカオス予測 (1/2)

- 右側のアイテム 1
- 右側のアイテム 2





Figure: Reservoir Computer の構造
Image: ReservoirPy, MIT License.

Reservoir Computer を用いたカオス予測 (2/2)

予測の手法

① 予測する系の時系列データを生成


- ▶ 外力付きの Rössler 方程式の系の場合, 変数 X_t, Y_t と外力 P_t から成る配列.

② Reservoir の Hyperparameter の最適化

- ▶ train 期間 で学習を行い, test 期間で教師付きの予測を行う.
- ▶ test 期間での予測値と真の値との誤差を目的関数として, 最適化を行う.

③ self-evolve 予測を行う.

- ▶ train, warm-up 期間 の後, Reservoir に未来予測をさせる.
- ▶ 各ステップの入力は, Reservoir の一期前の出力に対して, 外力の真の値だけ修正した配列.



周期外力のある Rössler モデル (1/2)

Rössler 方程式

次の方程式を解くことで時系列データを生成する.


$$\frac{dx}{dt} = -y - z + P(t) \quad (1)$$

$$\frac{dy}{dt} = x + ay \quad (2)$$

$$\frac{dz}{dt} = b + z(x - c) \quad (3)$$

ここで, $P(t) := A \sin(t + \theta_p(t))$ とする.
ただし, $p \in \{n \in \mathbb{Z} \mid -12 \leq n \leq 12\}$ とし,
 θ_p は 4 日に 1 度外力の位相を $p \cdot 2\pi/24$ だけ
早めるような関数.

Rössler Attractor with P(t)



周期外力のある Rössler モデル (2/2)

- Hyperparameter の最適化は位相シフトが 8 時間である系に対して行う。
- その後、同じ Reservoir で異なる位相シフトを持つ系に対しても予測を行う。
 - ▶ 未知の外力に対する Reservoir の予測性能を測る。




Figure: 4 日に一度 8 時間早めたときの外力の位相

Time Evolution of the Rössler System




Figure: 位相シフトのある周期外力付きの Rössler システム : 上から $x, y, z, P(t)$.

Appendix

Reservoir Computer による予測：手法

$\Delta t = 0.1$ とした.


- Hyperparameters の最適化

- ▶ 学習期間: Rössler システムにおける z 変数が観測できないものとして, x, y 変数 と 外力 $f(t)$ を入力する. 期間は $[0, 1000)$.
- ▶ 損失関数を学習期間全体に対して定義された nrmse として最適化：

$$\text{nrmse}(y, M) = \sqrt{\frac{\sum_{i=0}^{M-1} (y_i - \hat{y}_i)^2}{M}} \quad (4)$$

- ▶ Hyperparameters は Cell number (N), spectral radius (sr), leaking rate (lr), input scaling (iss), regularization (ridge), random seed(seed).
- ▶ 最適化アルゴリズムは TPE (Tree-structured Parzen Estimator) algorithm.
- Self-evolving 期間
 - ▶ warming up : $[1000, 1500]$, Self-evolving 期間: $[1500, 2510]$.

位相シフトのない周期外力を持つ Rössler モデル



連立微分方程式：

$$\frac{dx}{dt} = -y - z + A \sin(t) \quad (5)$$


$$\frac{dy}{dt} = x + ay \quad (6)$$

$$\frac{dz}{dt} = b + z(x - c) \quad (7)$$

- 外力の振幅 $A = 0.1$, 変数 $a = 0.2$, $b = 0.2$, $c = 5.7$, 初期条件 $[x, y, z] = [1.0, 1.0, 1.0]$. 時間範囲： $[0, 2510]$, 系の周期は 2π .

Figure: 位相シフトのない周期外力を持つ Rössler モデル

確定的な位相シフトの周期外力を持つ Van Der Pol モデル



Hyperparameters の最適化 (1/2)

アルゴリズムの話.

Hyperparameters の最適化 (2/2)

Hyperopt と Optuna の話.

Y. C. Lai et al. (2022) の結果 (1/2)

Reservoir Computer は Input, Hidden, Output の三つの層から構成される。

Reservoir Computer の構成 : Y. C. Lai et al. (2022)




Fig.1 from Y. C. Lai et al. (2022)

- $\mathbf{u}(t) \in \mathbb{R}^{D_{in}}$: input signal.
- $\mathbf{r}(t) \in \mathbb{R}^{D_r}$: hidden layer state vector.
- $f(t)$: (control) external driving signal.
- $\mathcal{W}_{in} \in D_r \times D_{in}$: Weighted input matrix.
- \mathcal{W}_c : Controller matrix.
- $\mathcal{W}_r \in D_r \times D_r$: Weighted network matrix inside.
- $\mathcal{W}_{out} : D_{out} \times D_r$: Output weighted matrix.

$\mathbf{u}(t)$ に時系列モデル (low/high-dimensional Lorenz-96 climate network, driven chaotic laser system など), $f(t)$ には sinusoidal 関数などを使用する (e.g. $f(t) = A \sin(\Omega t) + F$).

Y. C. Lai et al. (2022) の結果 (2/2)

学習期間全体の $\mathbf{u}(t)$, 全期間の $\mathbf{v}(t)$ を記録する行列をそれぞれ \mathcal{R}' , \mathcal{V} とする.

- $\mathcal{W}_{\text{in}}, \mathcal{W}_c, \mathcal{W}_r$ は Reservoir の学習に前もってランダムに定められる.
- 学習期間において, $\mathbf{u}(t)$ と $f(t)$ の実データが入力される. 学習期間の後の self-evolving 期間では, Reservoir による出力 $\mathbf{v}(t)$ と $f(t)$ の実データが予測の入力に用いられる.
 - ▶ $\mathbf{r}(t)$ は 学習期間, self-evolving 期間においてそれぞれ次の式で決定される.

$$\mathbf{r}(t + \Delta t) = (1 - \alpha)\mathbf{r}(t) + \alpha \tanh [\mathcal{W}_r \mathbf{r}(t) + \mathcal{W}_{\text{in}} \mathbf{u}(t) + \mathcal{W}_c f(t)] \quad (8)$$

$$\mathbf{r}(t + \Delta t) = (1 - \alpha)\mathbf{r}(t) + \alpha \tanh [\mathcal{W}_r \mathbf{r}(t) + \mathcal{W}_{\text{in}} \mathcal{W}_{\text{out}} \mathbf{r}'(t) + \mathcal{W}_c f(t)] \quad (9)$$

- 複数の $f(t)$ に対して Reservoir を sequential に学習させることで, 未知の外力がある場合でも予測できるようにする. また, Hyperparameter に関する最適化を行う (後述).
- Reservoir に次式における $\mathcal{V}, \mathcal{R}'$ 間の Linear Regression を通じて \mathcal{W}_{out} を学習させる.

$$\mathcal{W}_{\text{out}} = \mathcal{V} \cdot \mathcal{R}'^T (\mathcal{R}' \cdot \mathcal{R}'^T + \beta \mathbf{I})^{-1} \quad (10)$$

理論的な展開

Reservoir Computer の理論的な研究としては Boltt (2021) の研究などが挙げられる.

Boltt (2021)

Reservoir Computer の activation function (式 (8), (9) における \tanh 関数) を局所的に線型 activation function $q : \mathbb{R} \ni s \mapsto s \in \mathbb{R}$ とみなすことで, Reservoir 内のダイナミクスに関して次のを得る.

$$\mathbf{v}_{l+1} = \mathbf{W}^{\text{out}} \sum_{j=1}^{\ell} \mathbf{A}^{j-1} \mathbf{W}^{\text{in}} \mathbf{u}_{\ell-j+1} \quad (11)$$

式 (11) が VAR(NVAR) の係数行列を表すものとみなせる.

参考文献

- [1] Yamaguchi, Y., Suzuki, T., Mizoro, Y., Kori, H., Okada, K., Chen, Y., Fustin, J. M., Yamazaki, F., Mizuguchi, N., Zhang, J., Dong, X., Tsujimoto, G., Okuno, Y., Doi, M., and Okamura, H. (2013). Mice genetically deficient in vasopressin V1a and V1b receptors are resistant to jet lag. *Science (New York, N.Y.)*, 342(6154), 85 – 90.